

1. 請簡明扼要地闡述你如何抽取模型的輸入特徵 (feature)

答：

我實作兩類模型：線性函數 ($y = b + w \cdot x$) 及二次函數 ($y = b + w_1 \cdot x + w_2 \cdot x^2$)


- 線性函數只取前九小時的 pm2.5 指標做一維 feature
 $\text{train_x} = [x_1, x_2, x_3, x_4, x_5, x_6, x_7, x_8, x_9]$
- 二次函數使用前九小時的 pm2.5 指標做一維及二維 feature
 $\text{train_x} = [x_1, x_2, \dots, x_8, x_9, x_1^2, x_2^2, \dots, x_8^2, x_9^2]$

另外，在抽取 feature 之前，我先將 train.csv 裡的-1 以插值處理。

2. 請作圖比較不同訓練資料量對於 PM2.5 預測準確率的影響

答：

以 12 月的 pm2.5 指標作為 validation set，前 11 個月的資料則以「連續 n 個月之 pm2.5 指標」來訓練一維模型，n 為 1 至 11，若 n = 3，則取 1~3、2~4...8~10、9~11 月各自訓練一維模型並預測。不同 n 值的平均 RMSE 如下圖：



由上圖可知，訓練資料量越大，平均準確率越高。然而在相同 n 值裡，由於訓練資料不盡相同，準確率仍然會有落差，此處只比較平均值。

3. 請比較不同複雜度的模型對於 PM2.5 預測準確率的影響

答：

承第 1 題，我實作了兩種模型，分別為線性函數 ($y = b + w \cdot x$) 及二次函數 ($y = b + w_1 \cdot x + w_2 \cdot x^2$)

- 以 12 月作為 validation set、前 11 月的 pm2.5 指標訓練一維及二維模型，皆不做正規化，一維模型的 RMSE 為 5.44989047462，二維則為 5.82333093214。
→ 一維模型在 validation set 的表現也較二維模型好。

- 以 12 個月的所有 pm2.5 指標訓練一維及二維模型，且皆不做正規化，上傳至 Kaggle 後結果如下：

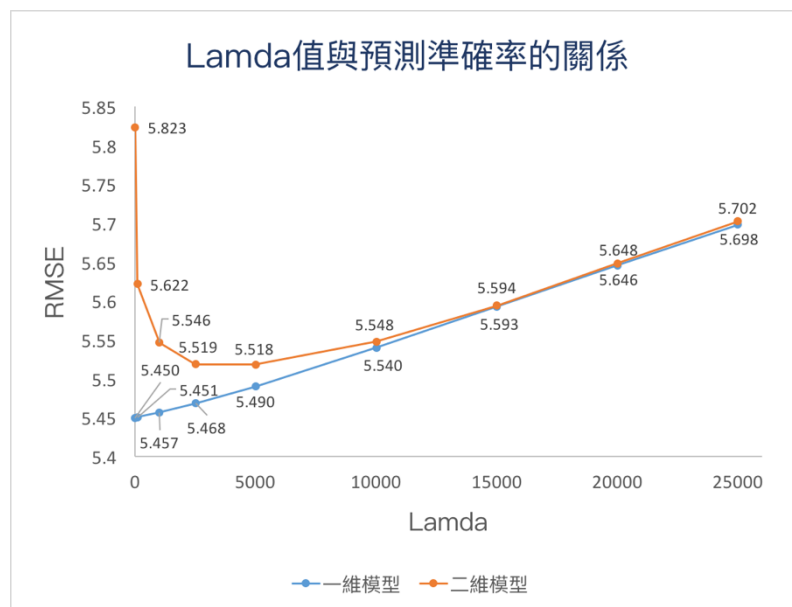
	Public Score	Private Score
一維模型	5.70451	7.18664
二維模型	5.82360	6.38991

由上表可知，一維模型在 public testing set 上的表現仍較二維模型好，但在 private testing set 上的結果則相反，因此推論二維模型在預測較大量資料時可能較有利。

4. 請討論正規化(regularization)對於 PM2.5 預測準確率的影響

答：

我以 12 月作為 validation set、前 11 月的 pm2.5 指標訓練一維及二維模型，比較 Lamda = 0, 100, 1000, 2500, 5000, 10000, 15000, 20000, 25000 時於一維模型及二維模型上的表現，結果如下圖：



→ Lamda 越大，一維模型在 validation set 上的表現越差，二維模型則在 Lamda = 5000 時表現最好。另外，Lamda ≥ 10000 時，兩種模型之準確率與 Lamda 值的關係很相似，此時 Lamda 值變大對準確率有負面影響。

5. 在線性回歸問題中，假設有 N 筆訓練資料，每筆訓練資料的特徵 (feature) 為一向量 x^n ，其標註(label)為一存量 y^n ，模型參數為一向量 w (此處忽略偏權值 b)，則線性回歸的損失函數(loss function)為 $\sum_{n=1}^N (y^n - w \cdot x^n)^2$ 。若將所有訓練資料的特徵值以矩陣 $X = [x^1 x^2 \dots x^N]$ 表示，所有訓練資料的標註以向量 $y = [y^1 y^2 \dots y^N]^T$ 表示，請以 X 和 y 表示可以最小化損失函數的向量 w 。

答： $w = (X^T X)^{-1} X^T y$